



TRAS LAS HUELLAS DEL OSO POLAR

CONTEXTO Y OBJETIVO.

- Seguimiento de osas polares vía GPS (proyecto CTCRW)
 - Analizar **patrones de movimiento** y predicción de su actividad diaria
 - Aplicar ML para segmentar, predecir y clasificar estilos de vida
 - Dataset: Polar Bear CTCRW Movement Data – USGS, alaska.usgs.gov)
-

CONTEXTO Y OBJETIVO.

- **¿Qué distancia media recorre?**
 - **Tipo:** Regresión
 - **Target:** distance_per_day
 - **Modelos:** Linear Regression, Ridge, Random Forest
 - **¿Clasificar patrones de movimiento (activo, estacionario)?**
 - **Tipo:** Clasificación
 - **Target:** movement_pattern
 - **Modelos:** Logistic Regression, Random Forest
 - **¿Segmentar osos por estilo de movimiento?**
 - **Tipo:** Clustering (no supervisado)
 - **Target:** —
 - **Modelos:** KMeans, PCA
-

FLUJO DE DATOS (PIPELINE).

CSV Original → Limpieza & EDA → FE → Enriquecimiento ambiental



Clustering / Regresión / Clasificación



Resultados interactivos en Streamlit

EDA: DISTRIBUCIONES CLAVE

- Distancia diaria recorrida
 - Días de seguimiento por osa
 - Patrones de velocidad y aceleración
 - Distribución geográfica (lat/lon)
-

FE: VARIABLES EXTERNAS, VARIABLES DERIVADAS...

UniqueAnimalID	timestamp	mu_lat	mu_lon	se_mu_x	se_mu_y
1	7/1/1986 0:00	69.7687	-141.3759	14589	14589
1	7/1/1986 6:00	69.7703	-141.3863	12248	12248
1	7/1/1986 12:00	69.7718	-141.3942	9375	9375
1	7/1/1986 18:00	69.7730	-141.3960	5835	5835
1	7/2/1986 0:00	69.7738	-141.3834	2517	2517



24	distance_per_day	2942
25	AvgLatitude	2942
26	AvgLongitude	2942
27	Year	2942
28	season	2942
29	x_proj	2942
30	y_proj	2942
31	prev_se_x	2938
32	prev_se_y	2938
33	bearing	2938
34	prev_bearing	2934
35	bearing_change	2942
36	distance_per_day_real	294215 non-null float64
37	movement_pattern	294215 non-null object
38	month	294215 non-null int32

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 294215 entries, 0 to 294214
Data columns (total 39 columns):
#   Column                                Non-Null Count  Dtype
---  -
0   UniqueAnimalID                       294215 non-null int64
1   timestamp                             294215 non-null datetime64[ns]
2   mu_lat                                294215 non-null float64
3   mu_lon                                294215 non-null float64
4   se_mu_x                               294215 non-null int64
5   se_mu_y                               294215 non-null int64
6   adj_lat                               294215 non-null float64
7   adj_lon                               294215 non-null float64
8   prev_lat                              293822 non-null float64
9   prev_lon                              293822 non-null float64
10  prev_time                             294215 non-null datetime64[ns]
11  distance_km                            294215 non-null float64
12  time_diff_hr                          294215 non-null float64
13  velocity_kmh                          294215 non-null float64
14  prev_velocity                         294215 non-null float64
15  acceleration_kmph2                    294215 non-null float64
16  date                                  294215 non-null object
17  daylight_hours                        294215 non-null float64
18  is_polar_night                        294215 non-null bool
19  is_midnight_sun                       294215 non-null bool
20  min                                   294215 non-null datetime64[ns]
21  max                                   294215 non-null datetime64[ns]
22  dias_tracking                         294215 non-null int64
23  TotalDistance_km                      294215 non-null float64
```

CLUSTERING.

- **Mapa geográfico:** clusters por región/ estilo de movimiento
 - **Radar chart:** perfil comparativo por cluster
 - **Insight:** los clusters reflejan diferencias claras de movilidad y zonas preferidas
-

CLUSTERING – MAPA + RADAR + INSIGHT. KMEAN + PCA



Resumen por cluster:				
	distance_per_day	bearing_change	velocity_kmh	acceleration_kmph2
cluster				
0	12.666892	12.872808	0.609983	-0.035496
1	13.117842	43.832140	0.700750	-0.019974
2	15.324366	19.322261	1.769425	0.110983

k	Silhouette Score
3	0.236
5	0.245

REGRESIÓN – TABLA MÉTRICAS + IMPORTANCIAS

- **Tabla de métricas:** MAE, RMSE, R^2 (mejor modelo: Random Forest)
- **Importancia de variables:** velocity_kmh y acceleration_kmph2 dominan la predicción
- **Predicción interactiva:** permite estimar la distancia diaria dada la actividad y posición

distance_per_day vs. distance_per_day_real

-
- **Objetivo:** Estimar los km recorridos al día según velocidad, aceleración, posición y estación.
 - **Modelo:** Random Forest, comparado con regresión lineal y Ridge.
 - **Precisión:** MAE $\approx$ 4.8 km/día, $R^2 \approx 0.57$ (test).
 - **Aplicación:** Predicción diaria lista para uso interactivo en la app.

Modelo	MAE train	MAE test	RMSE train	RMSE test	R^2 train	R^2 test	CV R^2 (5-fold)
RandomForest	4.704429	4.812572	9.418140	9.731049	0.622278	0.571356	0.569622
Ridge (scaled)	5.020149	4.936194	10.851222	10.393691	0.498583	0.510991	0.499179
Linear (scaled)	5.020149	4.936194	10.851222	10.393691	0.498583	0.510991	0.499179

CLASIFICACIÓN – AUC, MATRIZ CONFUSIÓN.

- **AUC y matriz de confusión:** buen recall en clase minoritaria (activo)
- **class_weight='balanced'** para corregir desbalance
- **Modelo robusto:** Logistic Regression + Random Forest

movement_pattern



CLASIFICACIÓN – AUC, MATRIZ CONFUSIÓN.

- **Objetivo:** Predecir si la osa polar está “activa” o “estacionaria” a partir de variables de movimiento y estación.
 - **Modelo:** Regresión logística con pesos balanceados (corrige desbalance 75/25).
 - **Precisión:** ROC AUC ≈ 0.84 . Buen recall en clase minoritaria (“activo”).
 - **Aplicación:** Detección automática de días activos/estacionarios para análisis ecológico.
-

	precision	recall	f1-score	support
activo	0.66	0.84	0.74	22066
estacionario	0.94	0.86	0.90	66199
accuracy			0.85	88265
macro avg	0.80	0.85	0.82	88265
weighted avg	0.87	0.85	0.86	88265


ROC AUC: 0.9221589292538019

AUC media (5-fold): 0.9223960299442613



STREAMLIT.

- Secciones de cluster, regresión y clasificación
- Interfaz para jugar con variables y visualizar el impacto
- Demo: predicción en tiempo real y mapa de clusters



CONCLUSIONES .

- **Identificamos perfiles de movilidad** relevantes para conservación
 - **Modelo predictivo fiable:** ayuda a anticipar rutas y riesgos
 - **Herramienta interactiva** para tomar decisiones basadas en datos
-

FUTURO/MEJORAS.

- Integrar más variables ambientales (hielo, meteo)
 - Probar modelos avanzados (XGBoost, Deep Learning)
 - Sistema de alertas para eventos anómalos
-